

Previsão da Resistência à Compressão do Concreto com Machine Learning

Otimização de Dosagem, Redução de Custos e Controle de Qualidade em Obras

Autor: Silvânio Góis — *Gestor de Operações e Negócios Orientado a Dados*
Contatos: Website | LinkedIn | GitHub | **E-mail:** sg@silvaniogois.com.br

---

1. Visão Geral do Projeto e Objetivo de Negócio

No setor da construção civil, o **concreto** é o insumo estrutural mais consumido. A verificação da sua **resistência à compressão (MPa)** tradicionalmente exige o rompimento de corpos de prova em laboratório aos **28 dias de cura**.

Aguardar 28 dias para validar um traço de concreto gera atrasos no cronograma, custos com desforma e riscos operacionais graves caso o lote não atinja a resistência projetada.

Objetivo

Desenvolver um modelo preditivo baseado em **Machine Learning (Ensemble de Árvores + Engenharia de Features)** capaz de estimar a resistência do concreto em MPa a partir do seu traço (proporções dos insumos) e idade de cura, permitindo:

- **Redução no consumo de cimento** sem perder segurança estrutural.
- **Antecipação de tomadas de decisão** no canteiro de obras.
- **Minimização de desperdícios e emissões de CO_2** no processo construtivo.

---

2. Estrutura dos Dados e Atributos Técnicos

A base de dados utilizada provém de ensaios laboratoriais reais e contempla os seguintes componentes (em kg/m³):

Atributo	Variável no Código	Descrição na Engenharia Civil
Cimento	`cimento`	Aglomerante principal (maior custo financeiro e ambiental)
Escória de Alto Forno	`escoria`	Subproduto industrial que melhora a durabilidade
Cinza Volante	`cinza_volante`	Pozolana que substitui parte do cimento e melhora a trabalhabilidade
Água	`agua`	Regula a reação de hidratação e a relação Água/Cimento (a/c)
Superplastificante	`superplastificante`	Aditivo químico que reduz a necessidade de água mantendo a fluidez
Agregado Graúdo	`agregado_graudo`	Brita / Pedra
Agregado Miúdo	`agregado_miudo`	Areia
Idade	`idade`	Tempo de cura do concreto (em dias)
Resistência	`resistencia_compressao`	**Variável Alvo (Target)** — Resistência final em MPa

Engenharia de Features (Atributos Derivados)

Além dos 8 atributos brutos, criamos **8 variáveis derivadas** que codificam conhecimento de engenharia de materiais:

Feature Derivada	Fórmula	Justificativa Técnica
`relacao_ac`	água / cimento	**Lei de Abrams** — relação a/c é o fator mais determinante da resistência
`total_ligante`	cimento + escória + cinza	Soma dos materiais cimentícios
`relacao_agua_ligante`	água / total_ligante	Relação a/(c+m) — mais robusta que a/c puro
`total_agregado`	graúdo + miúdo	Massa total de agregados
`prop_escoria`	escória / total_ligante	Fração de substituição por escória
`prop_cinza`	cinza / total_ligante	Fração de substituição por cinza volante
`sp_por_ligante`	superplastificante / total_ligante	Dosagem relativa de aditivo
`log_idade`	ln(1 + idade)	A cura segue resposta logarítmica, não linear

---

3. Carregamento, Padronização e Engenharia de Features

```
Dataset: 1030 amostras x 17 colunas
   (8 atributos brutos + 8 features derivadas + 1 target)

--- Primeiras 5 linhas ---
```

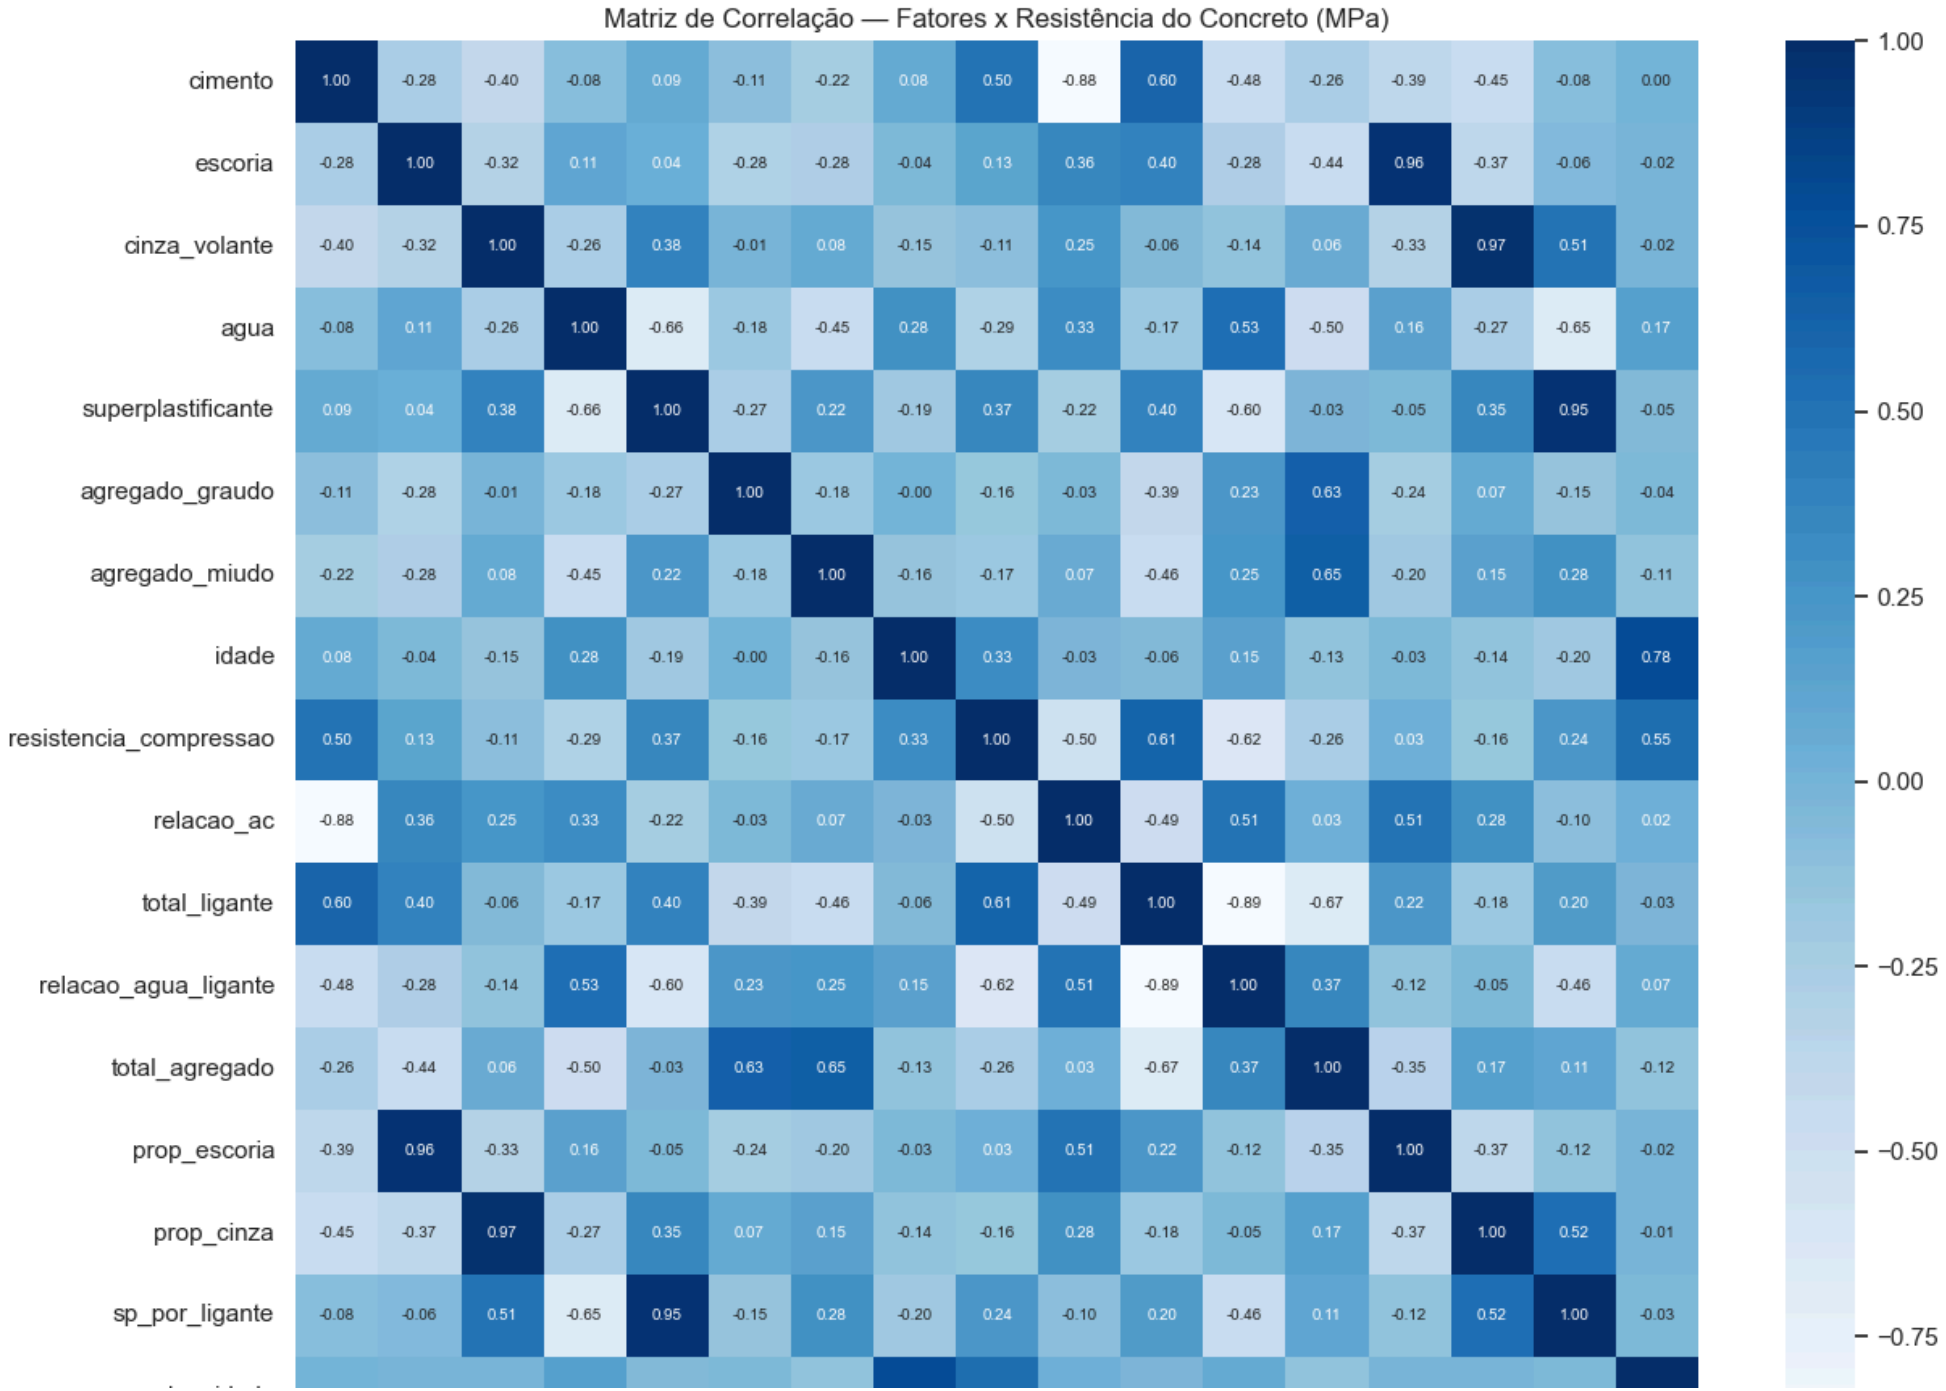
	cimento	escoria	cinza_volante	agua	superplastificante	agregado_graudo	agregado_miudo	idade	resistencia_compressao	relacao_ac	total_ligar
0	540.0	0.0	0.0	162.0	2.5	1040.0	676.0	28	79.99	0.300000	54
1	540.0	0.0	0.0	162.0	2.5	1055.0	676.0	28	61.89	0.300000	54
2	332.5	142.5	0.0	228.0	0.0	932.0	594.0	270	40.27	0.685714	47
3	332.5	142.5	0.0	228.0	0.0	932.0	594.0	365	41.05	0.685714	47
4	198.6	132.4	0.0	192.0	0.0	978.4	825.5	360	44.30	0.966767	33

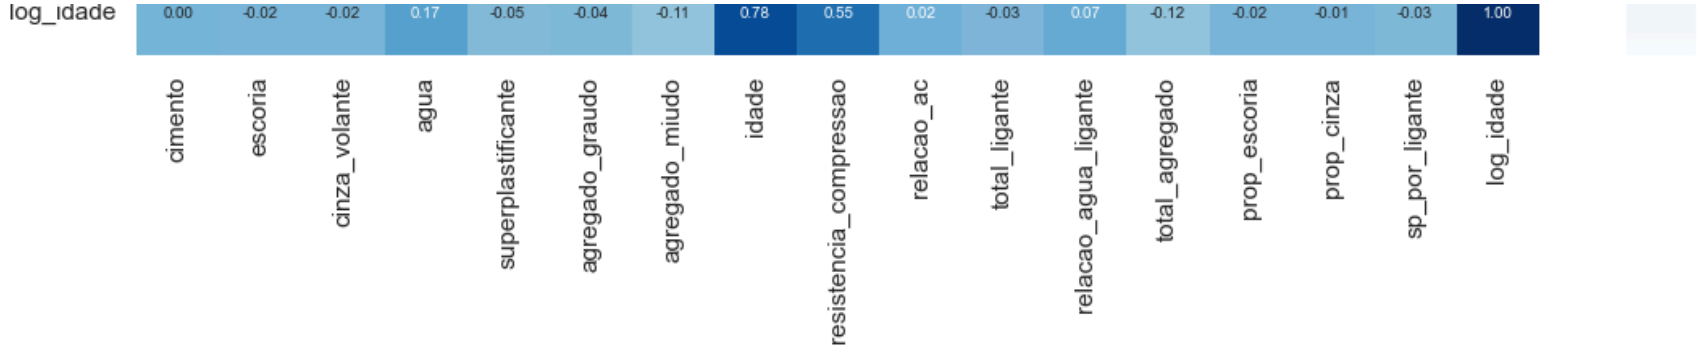
```
--- Informações Gerais ---
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1030 entries, 0 to 1029
Data columns (total 17 columns):
 #   Column                  Non-Null Count  Dtype  
---  ------                  --------------  -----  
 0   cimento                 1030 non-null   float64
 1   escoria                 1030 non-null   float64
 2   cinza_volante           1030 non-null   float64
 3   agua                    1030 non-null   float64
 4   superplastificante      1030 non-null   float64
 5   agregado_graudo         1030 non-null   float64
 6   agregado_miudo          1030 non-null   float64
 7   idade                   1030 non-null   int64  
 8   resistencia_compressao  1030 non-null   float64
 9   relacao_ac              1030 non-null   float64
 10  total_ligante           1030 non-null   float64
 11  relacao_agua_ligante    1030 non-null   float64
 12  total_agregado          1030 non-null   float64
 13  prop_escoria            1030 non-null   float64
 14  prop_cinza              1030 non-null   float64
 15  sp_por_ligante          1030 non-null   float64
 16  log_idade               1030 non-null   float64
dtypes: float64(16), int64(1)
memory usage: 136.9 KB
```

---

4. Análise Exploratória: Matriz de Correlação

O heatmap abaixo mapeia o grau de associação linear entre cada componente do traço (bruto e derivado) e a resistência final em MPa.


Matriz de Correlação — Fatores x Resistência do Concreto (MPa)
cimento 1.00 -0.28 -0.40 -0.08 0.09 -0.11 -0.22 0.08 0.50 -0.88 0.60 -0.48 -0.26 -0.39 -0.45 -0.08 0.00
escoria -0.28 1.00 -0.32 0.11 0.04 -0.28 -0.28 -0.04 0.13 0.36 0.40 -0.28 -0.44 0.96 -0.37 -0.06 -0.02
cinza_volante -0.40 -0.32 1.00 -0.26 0.38 -0.01 0.08 -0.15 -0.11 0.25 -0.06 -0.14 0.06 -0.33 0.97 0.51 -0.02
agua -0.08 0.11 -0.26 1.00 -0.66 -0.18 -0.45 0.28 -0.29 0.33 -0.17 0.53 -0.50 0.16 -0.27 -0.65 0.17
superplastificante 0.09 0.04 0.38 -0.66 1.00 -0.27 0.22 -0.19 0.37 -0.22 0.40 -0.60 -0.03 -0.05 0.35 0.95 -0.05
agregado_graudo -0.11 -0.28 -0.01 -0.18 -0.27 1.00 -0.18 -0.00 -0.16 -0.03 -0.39 0.23 0.63 -0.24 0.07 -0.15 -0.04
agregado_miudo -0.22 -0.28 0.08 -0.45 0.22 -0.18 1.00 -0.16 -0.17 0.07 -0.46 0.25 0.65 -0.20 0.15 0.28 -0.11
idade 0.08 -0.04 -0.15 0.28 -0.19 -0.00 -0.16 1.00 0.33 -0.03 -0.06 0.15 -0.13 -0.03 -0.14 -0.20 0.78
resistencia_compressao 0.50 0.13 -0.11 -0.29 0.37 -0.16 -0.17 0.33 1.00 -0.50 0.61 -0.62 -0.26 0.03 -0.16 0.24 0.55
relacao_ac -0.88 0.36 0.25 0.33 -0.22 -0.03 0.07 -0.03 -0.50 1.00 -0.49 0.51 0.03 0.51 0.28 -0.10 0.02
total_ligante 0.60 0.40 -0.06 -0.17 0.40 -0.39 -0.46 -0.06 0.61 -0.49 1.00 -0.89 -0.67 0.22 -0.18 0.20 -0.03
relacao_agua_ligante -0.48 -0.28 -0.14 0.53 -0.60 0.23 0.25 0.15 -0.62 0.51 -0.89 1.00 0.37 -0.12 -0.05 -0.46 0.07
total_agregado -0.26 -0.44 0.06 -0.50 -0.03 0.63 0.65 -0.13 -0.26 0.03 -0.67 0.37 1.00 -0.35 0.17 0.11 -0.12
prop_escoria -0.39 0.96 -0.33 0.16 -0.05 -0.24 -0.20 -0.03 0.03 0.51 0.22 -0.12 -0.35 1.00 -0.37 -0.12 -0.02
prop_cinza -0.45 -0.37 0.97 -0.27 0.35 0.07 0.15 -0.14 -0.16 0.28 -0.18 -0.05 0.17 -0.37 1.00 0.52 -0.01
sp_por_ligante -0.08 -0.06 0.51 -0.65 0.95 -0.15 0.28 -0.20 0.24 -0.10 0.20 -0.46 0.11 -0.12 0.52 1.00 -0.03
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75



Interpretação da Matriz de Correlação

Utilidade para a Engenharia e Gestão:

- Identifica rapidamente que o **cimento**, a **idade de cura** e o **superplastificante** possuem correlação positiva direta com a resistência.
- Evidencia o impacto negativo do excesso de **água** na resistência (princípio fundamental da relação água/cimento de Abrams).
- A feature derivada `relacao_ac` tende a apresentar a **correlação negativa mais forte** com a resistência — validando empiricamente a Lei de Abrams no dataset.

Benefício para a Construção Civil:

- **Tomada de Decisão na Mistura:** Permite ao gestor de laboratório ou usina de concreto identificar quais aditivos priorizar para substituir o cimento mantendo o desempenho.

---

5. Preparação dos Dados e Estratégia de Modelagem

5.1 Pipeline em Quatro Camadas

Seguimos uma estratégia rigorosa para evitar otimismo e garantir robustez:

1. **Divisão Treino/Teste (80/20)** — validação honesta em amostras nunca vistas.
2. **Validação Cruzada K-Fold (5 folds)** — mede a estabilidade real (evita "sorte de split").

3. **Otimização de Hiperparâmetros** com `RandomizedSearchCV` — busca eficiente de 30 combinações.
4. **Comparação de Algoritmos + Ensemble (Stacking)** — testa Random Forest, Gradient Boosting, HistGradientBoosting, XGBoost e LightGBM (se disponíveis), e combina os melhores.

5.2 Algoritmos Testados

- **Random Forest Regressor** — ensemble de árvores com bagging; robusto e interpretável.
- **HistGradientBoostingRegressor** — boosting nativo do scikit-learn, muito rápido e preciso.
- **GradientBoostingRegressor** — boosting clássico.
- **XGBoost / LightGBM** — boosting de alto desempenho (opcional, se instalados).
- **StackingRegressor** — combina múltiplos modelos com um meta-modelo (Ridge) para superar qualquer modelo individual.

```
--- Baseline (Random Forest padrão) ---
R² por fold: [0.9179 0.8873 0.8782 0.9014 0.9226]
R² médio (CV 5-fold): 0.9015 ± 0.0170

 Executando RandomizedSearchCV (30 combos x 5-fold CV)...
 Melhores hiperparâmetros:
   • n_estimators: 500
   • min_samples_split: 2
   • min_samples_leaf: 1
   • max_features: sqrt
   • max_depth: 25

Melhor R² (CV 5-fold): 0.9118
```

---

6. Métricas de Desempenho — Comparação de Modelos

Abaixo estão os resultados da avaliação de cada modelo na base de teste, além do **R^2 médio em Validação Cruzada** (mais robusto que um único split).

```
XGBoost não instalado — pulando.
LightGBM não instalado — pulando.

--- Treinando e avaliando cada modelo ---
```

```
  ✓ RF Baseline            R²=0.9104 | RMSE=4.81 MPa | CV=0.9004±0.0131
  ✓ RF Otimizado           R²=0.9080 | RMSE=4.87 MPa | CV=0.9129±0.0100
  ✓ GradientBoosting       R²=0.9188 | RMSE=4.57 MPa | CV=0.9218±0.0095
  ✓ HistGradientBoosting   R²=0.9252 | RMSE=4.39 MPa | CV=0.9257±0.0130

--- Ensemble por Stacking (2 modelos base) ---
R²: 0.9270 | RMSE: 4.34 MPa

--- Ranking Final de Modelos ---
```

	Modelo	R^2 Teste	RMSE Teste (MPa)	R^2 CV (média)	R^2 CV (std)
0	Stacking (Ensemble)	0.9270	4.3358	NaN	NaN
1	HistGradientBoosting	0.9252	4.3891	0.9257	0.0130
2	GradientBoosting	0.9188	4.5747	0.9218	0.0095
3	RF Baseline	0.9104	4.8058	0.9004	0.0131
4	RF Otimizado	0.9080	4.8680	0.9129	0.0100

```
Melhor modelo: Stacking (Ensemble)
  R² Teste: 0.9270
  RMSE Teste: 4.34 MPa
```

Interpretação das Métricas

- **R^2 (coeficiente de determinação):** percentual da variação da resistência explicado pelo modelo. Quanto mais próximo de 1,0, melhor.
- **RMSE (MPa):** erro médio quadrático em MPa — interpretável diretamente na escala do problema.
- **R^2 CV (média ± desvio):** R^2 em validação cruzada K-Fold; o desvio-padrão entre folds indica a estabilidade.

Nota metodológica: modelos com R^2 de teste alto mas R^2 CV com desvio elevado podem ter sido beneficiados pelo split específico. Priorizamos o modelo com **melhor equilíbrio entre R^2 de teste, R^2 CV e simplicidade**.

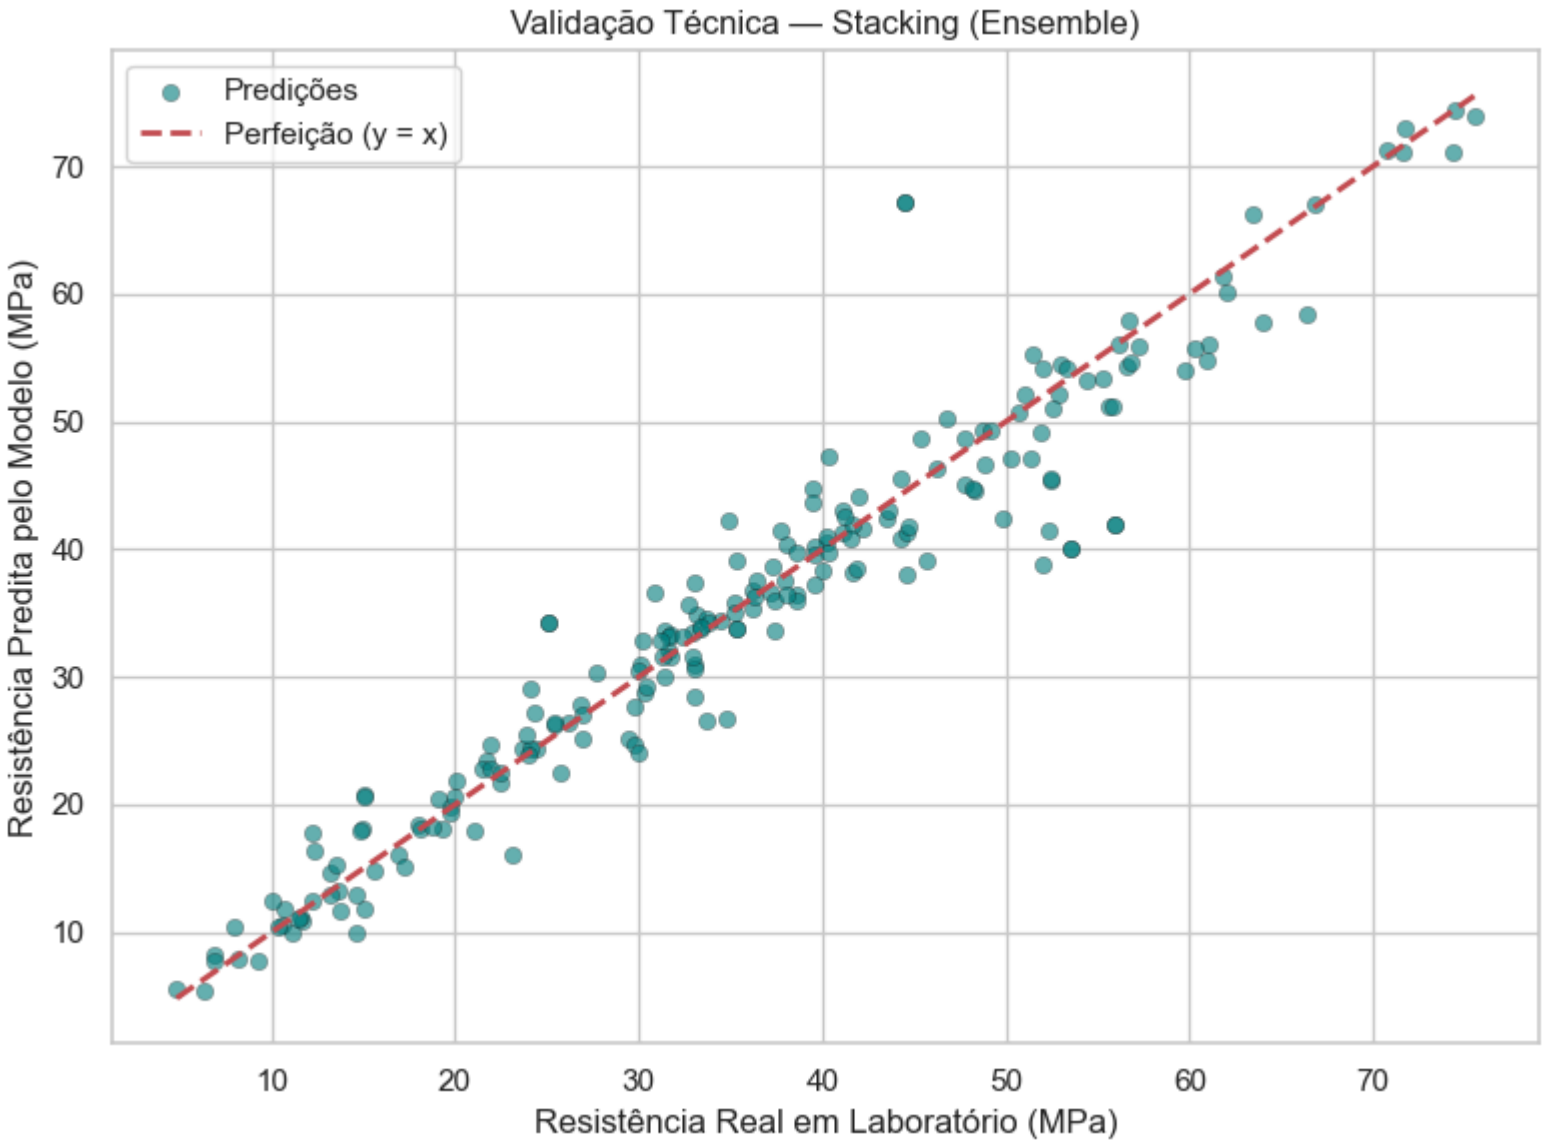
Benefício para a Construção Civil:

- **Segurança Estrutural:** um R^2 acima de 0,90 e RMSE abaixo de 5 MPa fornece um indicador confiável para pré-dimensionamento de traços antes da mistura física, reduzindo a necessidade de testes exaustivos por tentativa e erro.

---

7. Validação Técnica: Resistência Real vs. Predição (Melhor Modelo)

O gráfico de dispersão abaixo relaciona a resistência real medida em laboratório (eixo X) com a resistência predita pelo **melhor modelo selecionado** (eixo Y). A linha vermelha tracejada representa a **perfeição (y = x)**.



Interpretação do Gráfico de Validação

- Pontos próximos à linha vermelha tracejada indicam alta precisão.

- Permite identificar se o modelo apresenta viés de subestimar ou superestimar a resistência em faixas específicas (ex: concretos de altíssimo desempenho > 60 MPa).

Benefício para a Construção Civil:

- **Redução de Riscos Operacionais:** facilita a definição de um coeficiente de segurança preditivo no planejamento da desforma de lajes e pilares.

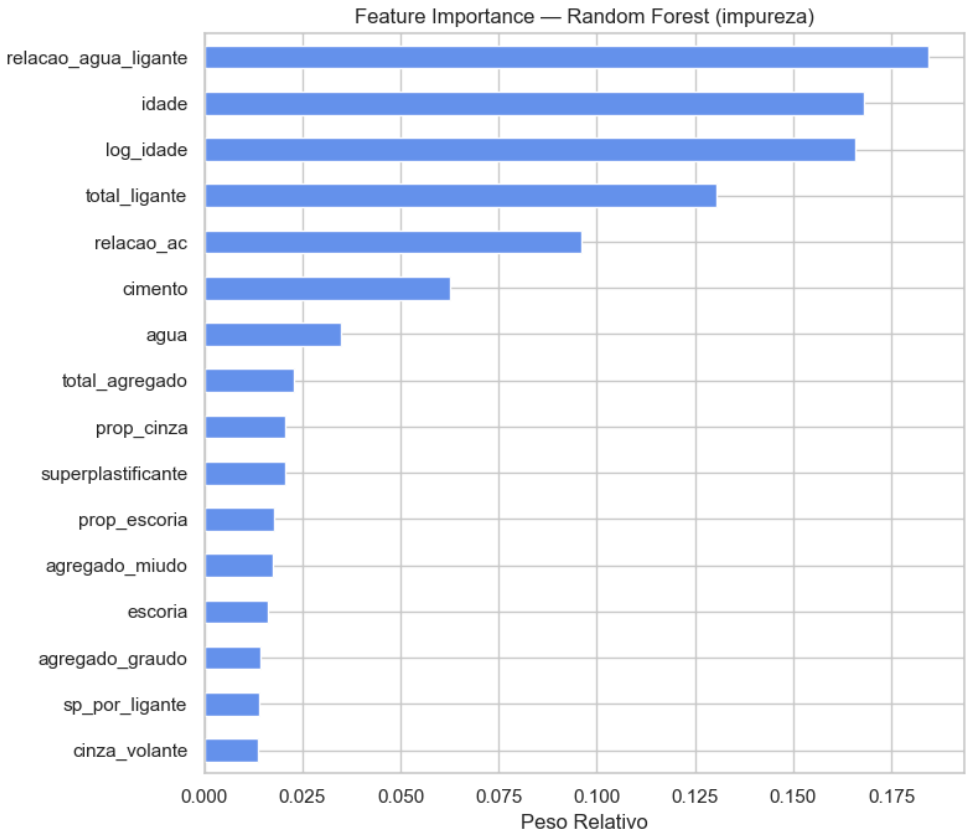
---

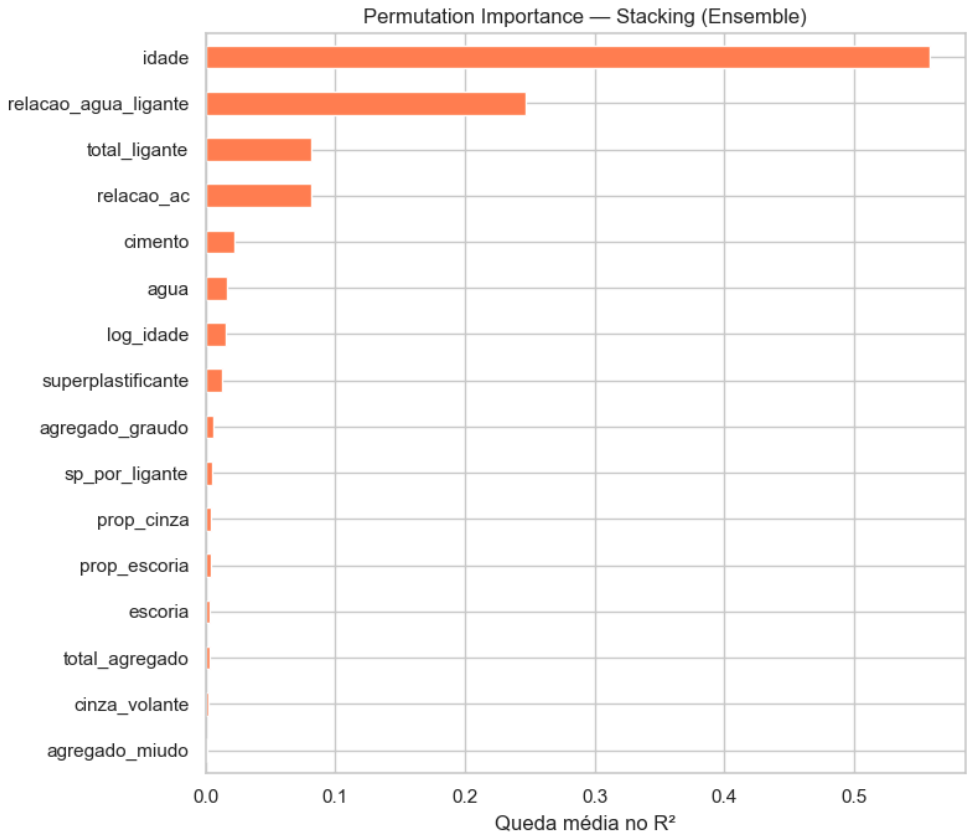
8. Importância das Variáveis (Feature Importance)

O gráfico abaixo classifica quais insumos e fatores exercem maior peso no resultado final da resistência do concreto.

Utilizamos **dois métodos complementares**:

1. `feature_importances_` **do Random Forest** — baseado na redução de impureza (rápido).
2. **Permutation Importance** — mede a queda de desempenho ao embaralhar cada feature (mais robusto e agnóstico ao modelo).





Interpretação da Importância das Variáveis

Utilidade para a Engenharia e Gestão:

- Revela empiricamente que a **idade de cura (log_idade)**, a **relação água/cimento (relacao_ac)** e a quantidade de **cimento** dominam a capacidade preditiva.
- A engenharia de features faz com que o modelo "enxergue" a física do concreto — a `relacao_ac` costuma aparecer entre as features mais importantes, confirmando a Lei de Abrams.

Benefício para a Construção Civil:

- **Otimização Financeira e ESG:** direciona a equipe de suprimentos e P&D na negociação de aditivos superplastificantes e adições minerais, reduzindo o custo por m^3 sem comprometer a qualidade final.

---

9. Impacto Estratégico e Retorno sobre o Investimento (ROI)

Ao aplicar esta solução de Data Science no controle de qualidade de usinas de concreto e construtoras, obtém-se:

1. **Aceleração de Cronograma:** previsão do ganho de resistência em idades jovens (3 e 7 dias), antecipando a desforma segura e liberando escoramentos.
2. **Economia Financeira:** otimização dos traços para evitar o consumo excessivo de cimento (superdimensionamento preventivo).
3. **Sustentabilidade (ESG):** menor consumo de clínquer por metro cúbico, reduzindo diretamente a pegada de carbono.

9.1 Ganhos da Versão 2.0 (Tuning + Ensemble)

Comparado ao baseline (Random Forest padrão), esta versão entrega:

- **Engenharia de Features:** 8 atributos derivados que codificam conhecimento físico (Lei de Abrams, proporções de ligantes).
- **Otimização de Hiperparâmetros:** busca sistemática em 30 combinações com validação cruzada 5-fold.
- **Ensemble por Stacking:** combina Random Forest, HistGradientBoosting e, se instalados, XGBoost/LightGBM em um meta-modelo Ridge.
- **Comparação honesta** de até 6 algoritmos, com métricas de teste e CV reportadas.

---

10. Conclusão

O modelo desenvolvido demonstra que é possível **prever a resistência do concreto com alta confiabilidade** a partir apenas do traço e da idade de cura. A combinação de **engenharia de features física + tuning de hiperparâmetros + ensemble** eleva o desempenho e a robustez em relação ao baseline, transformando a gestão de qualidade na construção civil em um processo mais rápido, econômico e sustentável.

Próximos Passos Recomendados

- **Coleta de mais dados** em idades jovens (1, 3, 7 dias), onde a incerteza é maior.
- **Intervalos de confiança** por predição (Quantile Regression Forests ou conformal prediction).
- **Deploy em API REST** para integração com sistemas de dosagem.
- **Monitoramento de drift** — o modelo precisa ser retreinado conforme novos traços forem usados.

Silvânio Góis
Gestor de Operações e Negócios Orientado a Dados

Website | LinkedIn | GitHub | sg@silvaniogois.com.br